



**Jeu  
d'échec**

# **ANALYSE DE DONNÉES**

PAR : ELYES KACEM

1 ING 1


# SOMMAIRE

## DESCRIPTION DU PROJET

- 01** Titre
- 02** Lien Data set
- 03** Description des colonnes de data set
- 04** Objectifs et Questions de l'analyse

## TRAVAIL RÉALISÉ

- 01** Description des méthodes d'analyse et d'apprentissage adoptées
- 02** bibliothèques Python importées
- 03** Les modules implémentés
- 04** Les résultats obtenus



# DESCRIPTION DU PROJET

## 01

**Titre :** Analyse sur des parties de jeux d'échec d'un fichier contenant **1 MILLION DE PARTIES!** ( 1,000,056 parties )

## 02

**Lien du projet :**

[https://colab.research.google.com/drive/1sPT1RBTleMzuhzL7ig\\_-O\\_LGHPCdghdV?usp=sharing](https://colab.research.google.com/drive/1sPT1RBTleMzuhzL7ig_-O_LGHPCdghdV?usp=sharing)

**Lien data set :**

[https://database.lichess.org/standard/lichess\\_db\\_standard\\_rated\\_2014-09.pgn.bz2](https://database.lichess.org/standard/lichess_db_standard_rated_2014-09.pgn.bz2)

## 03

**Description des colonnes de data set :**

- **Event :** le type du partie
- **Site :** identifiant du partie
- **Black\_id:** identifiant du joueur noir

- **Black\_id :** identifiant du joueur blanc
- **Result:** le résultat de la partie : 0-1 : le noir est le gagnant, 1-0 : le blanc est le gagnant, 1/2-1/2 : Null.
- **UTCDate :** la date de la partie
- **UTCTime :** le temps du départ de la partie.
- **White\_ration :** Score du blanc.
- **Black\_ration :** Score du noir.
- **WhiteRaitingDiff:** les points gagnant du blanc.
- **BlackRaitingDiff:** les points gagnant du noir.
- **Opening :** l'ouverture de la partie.
- **ECO :** classification des ouvertures.
- **TimeControl :** temps maximum de la partie
- **Termination :** Type de terminaison de la partie : normal, time forfeit( temps épuisé ), rule infraction, Abandonned.
- **Translation :** les mouvements dans la partie.

## 04

**Objectifs et Questions de l'analyse :**

-Préparer les données ( elle était dans une mauvaise format ), faire un model et choisir un model plus précis ( J'ai utilisé la méthode de Tree classification ) et enregistrer le nouveau fichier et le model dans mon drive.

j'ai fait des études sur la probabilité de gagner la partie et d'avoir une partie null pour chaque joueur, nombres de parties pour chaque type de terminaison, des parties jouées par la journée et par les heures, les meilleur ouverture pour chaque joueur, faire des graphes sur la densité de scores en général pour les noirs et les blancs et sur le temps de controle pour les parties.

# TRAVAIL RÉALISÉ

## 01

### **Description des méthodes d'analyse et d'apprentissage adoptées :**

Pour faire le model d'apprentissage, j'ai utilisé la méthode de Tree classification pour préviser la fin de la partie ( si c'est le noir qui a gagné : 0, ou le blanc : 1, ou la partie est null: 2) et j'ai subdiviser les données en 2 groupes : données d'apprentissage (80%) et données de teste (20%). Cette méthode permet de faire une arbre de choix, en basant sur les données d'apprentissage. Mais ce type d'apprentissage fonctionne seulement sur les données réelles ou entier. Or j'ai des données de type chaine de caractère, donc j'ai essayé de coder ces données par un clé

de type réelle. Après la construction de l'arbre, j'ai tester la précision de ce model en prévisionant les données de test et comparer les résultat obtenu par les valeurs réelles.


Pour l'analyse, j'ai essayer d'organiser les données dans un fichier CSV ( car les données était sous une forme indéterminée ), puis, j'ai éliminer les lignes conenant les valeurs NaN, et j'ai sauvegarder le nouveau fichier dans le drive. Durant l'analyse, j'ai fais des graphes sur des différents informations en utilisant des différents bibliothèque et modules que vous le trouverez dans les parties suivants.

## 02

### Les bibliothèque python importés :

- **drive** : pour l'interaction avec mon drive.
- **csv** : pour construire un fichier csv ( contenant les données formater )
- **DecisionTreeClassifier** : pour construire le model d'apprentissage
- **train\_test\_split** : pour séparer les données d'apprentissage et les données du teste
- **accuracy\_score** : Pour calculer le score d'accurance.

La fin des parties de notre échantillon :




## 03

### Les modules implémentés :

- **seaborn, plot**
- **matplotlib.pyplot**
- **pandas**
- **sklearn.tree**
- **sklearn.model\_selection**
- **sklearn.metrics**
- **joblib**
- **google.colab**


la manière de terminaison pour les parties jouées :




## 04

### Les résultats obtenus :

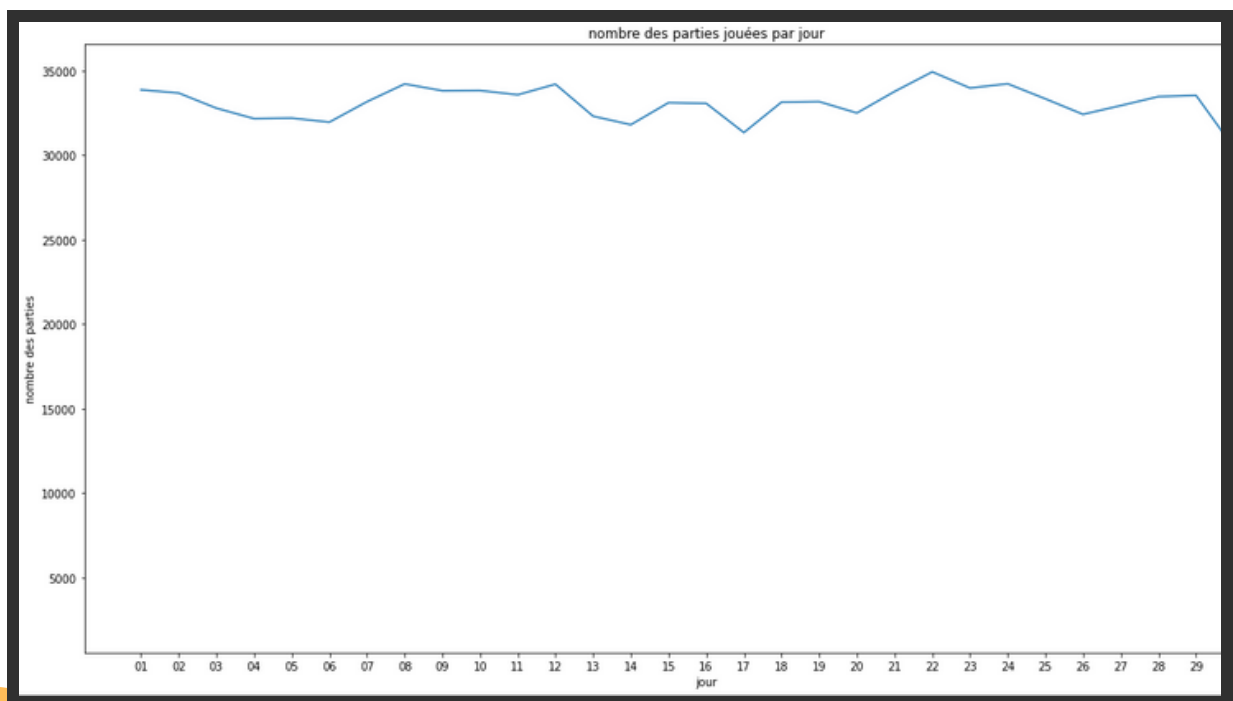
La probabilité de gagner un joueur ayant un score supérieur à votre score :



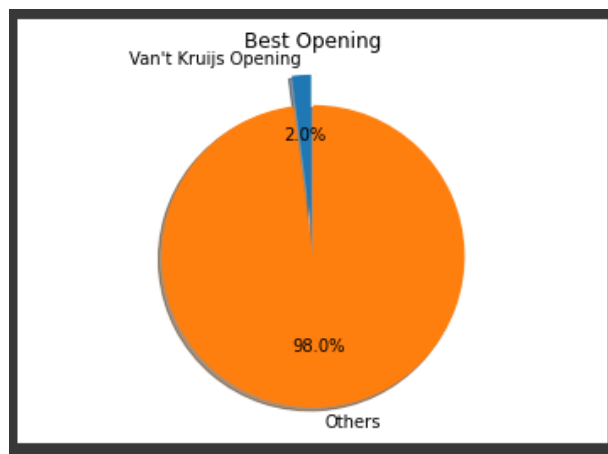
Nombre des parties jouées par heure :




Nombre des parties jouées par jour :



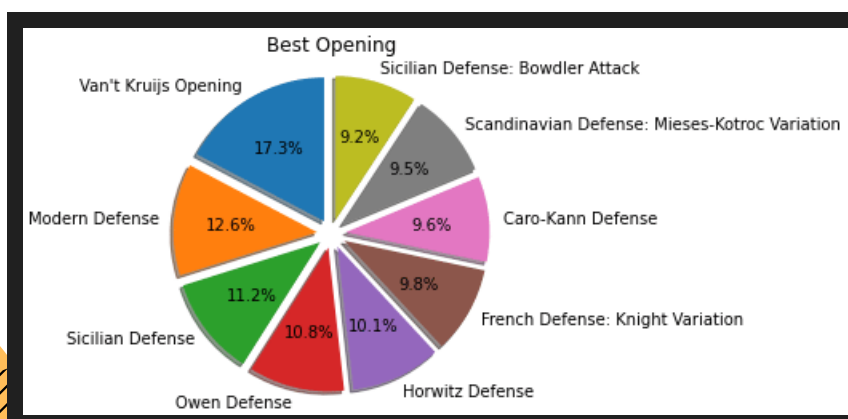
Si vous jouez par les blanc, la meilleur ouverture de jeu est :  
" Van't Krujis Opening "




Les 12 meilleur ouverture pour les blancs :




Les meilleurs ouvertures pour les noirs :



La densité de scores des joueurs blanc  
pour cet échantillon :



La densité de scores des joueurs noirs  
pour cet échantillon :



J'ai essayé de résumer mon projet dans ce fiche du projet. Pour savoir plus de détails sur le projets, veuillez ouvrir le lien du projet ( j'ai travaillé sur Google Collab ).  
J'espère que vous avez aimez mon projet.

Cordialement,